

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC VÀ KỸ THUẬT THÔNG TIN

BÁO CÁO THỰC HÀNH
MÔN: HỌC MÁY THỐNG KÊ

Họ và tên: Nguyễn Trương Phúc Nhã
MSSV: 24521223
Lớp: DS102.Q21.2

BÁO CÁO THỰC HÀNH

1. Dữ liệu và tiền xử lý

Bài thực hành sử dụng bộ dữ liệu Chest X-Ray Images (Pneumonia), gồm hai lớp ảnh: NORMAL và PNEUMONIA. Mục tiêu là huấn luyện mô hình Support Vector Machine để phân loại ảnh X-ray ngực thành hai lớp trên.

Dữ liệu được chia thành ba tập train, validation và test. Số lượng ảnh trong từng tập như sau:

Tập dữ liệu	NORMAL	PNEUMONIA	Tổng
Train	1341	3875	5216
Validation	8	8	16
Test	234	390	624
Tổng	1583	4273	5856

Có thể thấy tập train bị mất cân bằng lớp, trong đó số ảnh PNEUMONIA lớn hơn nhiều so với số ảnh NORMAL. Vì vậy, ngoài Accuracy, bài thực hành sử dụng thêm Precision, Recall và F1-score để đánh giá mô hình. Trong bài toán này, PNEUMONIA được xem là positive class.

Quy trình tiền xử lý ảnh gồm các bước: đọc ảnh bằng OpenCV, chuyển ảnh sang grayscale, resize về kích thước (128 x128), chuẩn hóa giá trị pixel về khoảng $[0,1]$, sau đó flatten ảnh thành vector một chiều. Sau khi flatten, mỗi ảnh được biểu diễn bởi $(128 \times 128 = 16384)$ đặc trưng.

Nhãn được mã hóa như sau:

NORMAL -> 1

PNEUMONIA -> -1

Sau tiền xử lý, kích thước dữ liệu là:

X_train shape: (5216, 16384)

y_train shape: (5216,)

X_val shape: (16, 16384)

y_val shape: (16,)

X_test shape: (624, 16384)

y_test shape: (624,)

2. Assignment 1: Cài đặt Soft-margin SVM bằng NumPy

Trong Assignment 1, mô hình Soft-margin SVM được cài đặt thủ công bằng NumPy và huấn luyện bằng thuật toán Stochastic Gradient Descent. Mô hình không sử dụng các lớp SVM có sẵn từ thư viện học máy.

Mô hình SVM tuyến tính

Với mỗi mẫu dữ liệu x_i và nhãn $y_i \in \{-1, 1\}$, hàm quyết định:

$$f(x_i) = w^T x_i + b$$

Mô hình dự đoán:

- Nếu $f(x_i) \geq 0 \rightarrow \text{NORMAL}$
- Nếu $f(x_i) < 0 \rightarrow \text{PNEUMONIA}$

Hàm mục tiêu (Soft-margin SVM)

$$J(w, b) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i (w^T x_i + b))$$

Trong đó:

- $\frac{1}{2} \|w\|^2$: regularization
- $\max(0, 1 - y_i (w^T x_i + b))$: hinge loss

Điều kiện margin

$$y_i (w^T x_i + b) \geq 1$$

Quy tắc cập nhật

Trường hợp 1: margin ≥ 1

$$\Delta w = w$$

$$\Delta b = 0$$

Trường hợp 2: margin < 1

$$\Delta w = w - C y_i x_i$$

$$\Delta b = -C y_i$$

Cập nhật bằng SGD

$$w = w - \eta \Delta w$$

$$b = b - \eta \Delta b$$

Cấu hình tốt nhất hiện tại của mô hình tự cài đặt là:


learning rate = 0.0001

epochs = 200

C = 1.0

random_state = 42

Loss được ghi nhận theo từng epoch để quan sát quá trình huấn luyện. Do mô hình được huấn luyện bằng SGD trên dữ liệu ảnh có số chiều lớn, loss vẫn có dao động giữa các epoch, nhưng kết quả đánh giá trên tập test tốt hơn so với các cấu hình ban đầu.



Hình 2. Training loss của mô hình Soft-margin SVM tự cài đặt bằng NumPy.

Kết quả trên tập test của mô hình SVM tự cài đặt là:

Metric	Giá trị
Accuracy	0.722756
Precision	0.695495
Recall	0.989744
F1-score	0.816931

Confusion matrix:

[[65 169]

[4 386]]

Với cách trình bày này, ma trận được hiểu là:

[[NORMAL -> NORMAL, NORMAL -> PNEUMONIA],

[PNEUMONIA -> NORMAL, PNEUMONIA -> PNEUMONIA]]

Mô hình tự cài đặt dự đoán đúng 65 ảnh NORMAL và 386 ảnh PNEUMONIA. Mô hình dự đoán nhầm 169 ảnh NORMAL thành PNEUMONIA và bỏ sót 4 ảnh PNEUMONIA. Recall đạt 0.989744, cho thấy mô hình phát hiện được phần lớn ảnh PNEUMONIA. Tuy nhiên, Precision chỉ đạt 0.695495 do số lượng False Positive còn cao.

3. Assignment 2: Huấn luyện SVM bằng thư viện scikit-learn

Trong Assignment 2, mô hình SVM được huấn luyện bằng thư viện scikit-learn. Mô hình được sử dụng là LinearSVC, phù hợp với dữ liệu đã được flatten thành vector đặc trưng nhiều chiều. Việc sử dụng SVM tuyến tính cũng giúp so sánh trực tiếp hơn với mô hình tự cài đặt ở Assignment 1.

Dữ liệu đầu vào của Assignment 2 được giữ nguyên như Assignment 1: ảnh grayscale, kích thước (128 x128), chuẩn hóa về $[0,1]$, sau đó flatten thành vector 16.384 chiều. Khi tính Precision, Recall và F1-score, PNEUMONIA tiếp tục được xem là positive class, tương ứng với nhãn (-1).

Kết quả trên tập test của mô hình SVM dùng thư viện là:

Metric	Giá trị
Accuracy	0.745192
Precision	0.713494
Recall	0.989744
F1-score	0.829216

Confusion matrix:

```
[[ 79 155]
```


```
 [ 4 386]]
```

Mô hình SVM dùng thư viện dự đoán đúng 79 ảnh NORMAL và 386 ảnh PNEUMONIA. Mô hình dự đoán nhầm 155 ảnh NORMAL thành PNEUMONIA và bỏ sót 4 ảnh PNEUMONIA. Recall bằng với mô hình tự cài đặt, nhưng Precision và F1-score cao hơn do mô hình thư viện giảm được số False Positive.

4. So sánh kết quả hai mô hình

Bảng sau trình bày kết quả so sánh giữa mô hình SVM tự cài đặt bằng NumPy và mô hình SVM dùng thư viện scikit-learn:

Metric	SVM tự cài đặt	SVM thư viện
Accuracy	0.722756	0.745192
Precision	0.695495	0.713494
Recall	0.989744	0.989744
F1-score	0.816931	0.829216



Hình 5. So sánh hiệu năng giữa mô hình SVM tự cài đặt và mô hình SVM dùng thư viện.

Kết quả cho thấy mô hình SVM dùng thư viện đạt Accuracy, Precision và F1-score cao hơn mô hình tự cài đặt. Cụ thể, Accuracy tăng từ 0.722756 lên 0.745192, Precision tăng từ 0.695495 lên 0.713494, và F1-score tăng từ 0.816931 lên 0.829216.

Recall của hai mô hình bằng nhau vì cả hai đều dự đoán đúng 386 ảnh PNEUMONIA và bỏ sót 4 ảnh PNEUMONIA. Do đó, khả năng phát hiện lớp PNEUMONIA của hai mô hình là tương đương trong thí nghiệm này. Điểm cải thiện chính của mô hình thư viện nằm ở lớp NORMAL: số ảnh NORMAL bị dự đoán nhầm thành PNEUMONIA giảm từ 169 xuống 155.

Như vậy, mô hình dùng thư viện không cải thiện Recall, nhưng cải thiện Precision và F1-score. Điều này cho thấy mô hình thư viện tạo ra ít cảnh báo nhầm hơn trong khi vẫn giữ được khả năng phát hiện PNEUMONIA tương đương với mô hình tự cài đặt.

5. Nhận xét và kết luận

Bài thực hành đã hoàn thành hai yêu cầu chính. Assignment 1 cài đặt được mô hình Soft-margin SVM bằng NumPy và huấn luyện bằng SGD. Assignment 2 huấn luyện được mô hình SVM bằng thư viện scikit-learn và so sánh kết quả với mô hình tự cài đặt.

Kết quả thực nghiệm cho thấy cả hai mô hình đều đạt Recall cao đối với lớp PNEUMONIA. Đây là điểm quan trọng vì trong bài toán phát hiện viêm phổi, False Negative là loại lỗi cần hạn chế. Tuy nhiên, cả hai mô hình vẫn còn số lượng False Positive tương đối lớn, nghĩa là nhiều ảnh NORMAL bị dự đoán thành PNEUMONIA.

Mô hình SVM dùng thư viện cho kết quả tổng thể tốt hơn mô hình tự cài đặt. Sự cải thiện chủ yếu nằm ở việc giảm False Positive, từ đó tăng Precision và F1-score. Tuy nhiên, mức cải thiện không quá lớn vì cả hai mô hình đều là SVM tuyến tính và đều sử dụng pixel thô sau khi flatten. Cách biểu diễn này chưa khai thác được cấu trúc không gian của ảnh X-ray.

Nhìn chung, mô hình tự cài đặt có giá trị trong việc hiểu rõ bản chất của Soft-margin SVM, bao gồm margin, hinge loss, regularization và cập nhật tham số bằng SGD. Mô hình dùng thư viện cho thấy lợi ích của các thuật toán tối ưu đã được cài đặt sẵn, giúp kết quả ổn định và tốt hơn trong cùng điều kiện dữ liệu.